



IPD-434 Seminario de Soft Computing



Sistemas Difusos (Fuzzy Systems)

Dr. Nicolás Gálvez Ramírez

Dr. Patricio Olivares Roncagliolo

Ingeniería Civil Telemática

Departamento de Electrónica

Universidad Técnica Federico Santa María

Fuente: "Introduction to Soft Computing, Neuro-Fuzzy and Genetic Algorithms", Samir Roy, Udit Chakraborty

Conjuntos difusos - Fuzzy Set

- Los conjuntos difusos corresponde a una **generalización** de los conjuntos clásicos.
- Resumen de la Teoría de Conjuntos clásica en el [Anexo 1](#).

Membresía en un conjunto

Función de membresía

- Considere un elemento x y un conjunto S .
- Se define la membresía x en S como $\mu_S(x)$ de la siguiente manera:

$$\mu_S(x) = \begin{cases} 1, & \text{if } x \in S \\ 0, & \text{if } x \notin S \end{cases}$$

- Ej:

$$A = \{\text{piedra, papel, tijera}\}$$

$$\mu_A(\text{piedra}) = 1$$

$$\mu_A(\text{spock}) = 0$$

Considere los siguientes conjuntos

$$U = \{72 \text{ años}, 63 \text{ años}, 41 \text{ años}, 38 \text{ años}, 13 \text{ años}, 15 \text{ años}, 52 \text{ años}\}$$

$$A = \{x \mid x \text{ es anciano}\}$$

Comprobando algunos elementos del conjunto U en la función de membresía $\mu_A(x)$

- 72 años se puede considerar anciano con seguridad, por lo tanto

$$\mu_A(72 \text{ años}) = 1$$

- 13 años se puede considerar que no es anciano con seguridad, por lo tanto

$$\mu_A(13 \text{ años}) = 0$$

Sin embargo, ¿qué ocurre en otros casos?

$$\mu_A(63 \text{ años}) = ?$$

$$\mu_A(41 \text{ años}) = ?$$

$$\mu_A(52 \text{ años}) = ?$$

Depende de cómo se define la **pertenencia** al conjunto anciano, lo cual no está **claramente** definido. Para estos casos, es conveniente expresar esta incertidumbre en la función de membresía.

Consideremos la siguiente función de membresía para el conjunto A :

$$\mu_A(x) = \begin{cases} 0, & \text{if } x < 30 \\ \frac{x-30}{40}, & \text{if } 30 \leq x < 70 \\ 1, & \text{if } x \geq 70 \end{cases}$$

Donde x representa la edad. Aplicando dicha función a los elementos en U :

$$\mu_A(72 \text{ años}) = 1.0$$

$$\mu_A(63 \text{ años}) = 0.825$$

$$\mu_A(41 \text{ años}) = 0.275$$

$$\mu_A(38 \text{ años}) = 0.2$$

$$\mu_A(13 \text{ años}) = 0.0$$

$$\mu_A(15 \text{ años}) = 0.0$$


$$\mu_A(52 \text{ años}) = 0.55$$

A continuación se muestra un gráfico de la función $\mu_A(x)$

```
In [1]: import matplotlib.pyplot as plt
import numpy as np

plt.rcParams['text.usetex'] = True
x = np.arange(0,100,1)
y1 = x[0:30]*0
y2 = (x[30:70]-30)/40
y3 = x[70:]*0 + 1
y = np.concatenate([y1, y2, y3])

fig = plt.figure()
ax = fig.add_subplot(1,1,1)
ax.set_title(r'Función de membresía  $\mu_A(x)$ ')
ax.set_xlabel(r'$x$')
ax.set_ylabel(r'$\mu_A(x)$')
ax.set_ylim(ymin=-0.1, ymax=1.1)
ax.set_ylim(bottom=0)
ax.set_xlim(xmin=-10, xmax=110)
ax.set_xlim(left=0)
ax.spines[['right', 'top']].set_visible(False)
ax.plot(x, y, 'r')
plt.grid()
plt.show()
```



Para enumerar los elementos pertenecientes al conjunto A , se debe incluir el valor de su función de membresía.

$$A = \{(72 \text{ años}, 1.0), (63 \text{ años}, 0.825), (41 \text{ años}, 0.275), (38 \text{ años}, 0.2), (52 \text{ años}, 0.55)\}$$

- No se agregan aquellos elementos con valor 0



Conjuntos difusos (Fuzzy sets)

- Agregan el concepto de **incerteza e imprecisión** a los conjuntos tradicionales.
- **Definición Formal:** Se define F como conjunto difuso dentro de un conjunto universo U como la colección de pares ordenados $(x, \mu_F(x))$ donde $x \in U$ y $\forall x \in U, 0.0 < \mu_F(x) \leq 1.0$.

$$F = \{(x, \mu_F(x)) \mid x \in U, 0.0 < \mu_F(x) \leq 1.0\}$$

- Cada par $(x, \mu_F(x))$ se conoce como **singleton**.

Notación de conjuntos difusos

- Además de enumerar singletons, los conjuntos difusos también se expresan con la siguiente notación

$$F = \sum_{x \in U} \frac{\mu_F(x)}{x}$$

donde $\sum$ representa unión de singletons, no suma aritmética.

- En conjuntos continuos, se reemplaza el símbolo de sumatoria con la integral

$$F = \int_U \frac{\mu_F(x)}{x}$$

Características de conjuntos difusos

- **Normalidad:** F es normal si al menos un elemento pertenece completamente a F

$$\exists x \mid \mu_F(x) = 1.0$$

- **Altura:**

$$\text{height}(F) = \max_{x \in U} \mu_F(x)$$

F es normal si $\text{height}(F) = 1.0$.

- **Soporte:**

$$\text{supp}(F) = \{x \mid x \in U, \mu_F(x) > 0\}$$

- **Núcleo:**

$$\text{core}(F) = \{x \mid x \in U, \mu_F(x) = 1\}$$

$$\text{core}(F) \subseteq \text{supp}(F)$$

Los conjuntos soporte y núcleo corresponden a conjuntos tradicionales (clásicos)

- **Cardinalidad:** Suma de los valores de membresía

$$|F| = \sum_{x \in U} \mu_F(x)$$

donde $\sum$ sí representa la suma aritmética de los valores $\mu_F(x)$

Funciones de membresía

- Una función de membresía puede ser cualquier función del tipo

$$\mu_F : U \rightarrow [0, 1]$$

Funciones de membresía frecuentes

Función triangular

$$\mu(x) = \begin{cases} 0, & \text{if } x < a \\ \frac{x-a}{m-a}, & \text{if } a \leq x < m \\ \frac{b-x}{b-m}, & \text{if } m \leq x < b \\ 0, & \text{if } x \geq b \end{cases}$$


```
In [2]: import matplotlib.pyplot as plt
import numpy as np

a = 30
m = 50
b = 80

plt.rcParams['text.usetex'] = True
x = np.arange(0,100,1)
y1 = x[:a]*0
y2 = (x[a:m]-a)/(m-a)
y3 = (b-x[m:b])/(b-m)
y4 = x[b:]*0
y = np.concatenate([y1, y2, y3, y4])
line_1 = np.ones(len(x))
y_m = np.linspace(0,1,len(x))
line_m = np.ones(len(x))*m

fig = plt.figure()
ax = fig.add_subplot(1,1,1)
ax.set_title(r'Función de membresía Triangular')
ax.set_xlabel(r"$x$")
ax.set_ylabel(r"$\mu(x)$")
ax.set_ylim(ymin=-0.1, ymax=1.1)
ax.set_ylim(bottom=0)
ax.set_xlim(xmin=-10, xmax=110)
ax.set_xlim(left=0)
ax.set_xticks([a,m,b])
ax.set_xticklabels(['a', 'm', 'b'])
ax.set_yticks([0.0, 1.0])
ax.spines[['right', 'top']].set_visible(False)
```

```
ax.plot(x, y, 'r', x, line_1, 'b--', line_m, y_m, 'g--')
plt.show()
```



Función trapezoidal

$$\mu(x) = \begin{cases} 0, & \text{if } x < a \\ \frac{x-a}{m-a}, & \text{if } a \leq x < m \\ 1, & \text{if } m \leq x < n \\ \frac{b-x}{b-n}, & \text{if } n \leq x < b \\ 0, & \text{if } x \geq b \end{cases}$$

```
In [3]: import matplotlib.pyplot as plt
import numpy as np

a = 20
m = 30
n = 50
b = 80


plt.rcParams['text.usetex'] = True
x = np.arange(0,100,1)
y1 = x[:a]*0
y2 = (x[a:m]-a)/(m-a)
y3 = np.ones(n-m)
y4 = (b-x[n:b])/(b-n)
y5 = x[b:]*0
```

```

y = np.concatenate([y1, y2, y3, y4, y5])
line_1 = np.ones(len(x))
y_m = np.linspace(0,1,len(x))
line_m = np.ones(len(x))*m
y_n = np.linspace(0,1,len(x))
line_n = np.ones(len(x))*n

fig = plt.figure()
ax = fig.add_subplot(1,1,1)
ax.set_title(r'Función de membresía Trapezoidal')
ax.set_xlabel(r'$x$')
ax.set_ylabel(r'$\mu(x)$')
ax.set_ylim(ymin=-0.1, ymax=1.1)
ax.set_ylim(bottom=0)
ax.set_xlim(xmin=-10, xmax=110)
ax.set_xlim(left=0)
ax.set_xticks([a, m, n, b])
ax.set_xticklabels(['a', 'm', 'n', 'b'])
ax.set_yticks([0.0, 1.0])
ax.spines[['right', 'top']].set_visible(False)
ax.plot(x, y, 'r', x, line_1, 'b--', line_m, y_m, 'g--', line_n, y_n, 'g--')
plt.show()

```



Función Gaussiana


$$\mu(x) = e^{-k(x-m)^2} \text{ where } k > 0$$

```
In [4]: import matplotlib.pyplot as plt
import numpy as np

m = 50
k = 0.005

plt.rcParams['text.usetex'] = True
x = np.arange(0,100,1)
y = np.exp(-k*(x-m)**2)
line_m = np.ones(len(x))*m
line_l = np.ones(len(x))

fig = plt.figure()
ax = fig.add_subplot(1,1,1)
ax.set_title(r'Función de membresía Gaussiana')
ax.set_xlabel(r"$x$")
ax.set_ylabel(r"$\mu(x)$")
ax.set_ylim(ymin=-0.1, ymax=1.1)
ax.set_ylim(bottom=0)
ax.set_xlim(xmin=-10, xmax=110)
ax.set_xlim(left=0)
ax.set_xticks([m])
ax.set_xticklabels(['m'])
ax.set_yticks([0.0, 1.0])
ax.spines[['right', 'top']].set_visible(False)
ax.plot(x, y, 'r', x, line_l, 'b--', line_m, y_m, 'g--')
plt.show()
```



Función-S


$$\mu(x) = \begin{cases} 0, & \text{if } x < a \\ 2\left(\frac{x-a}{b-a}\right)^2, & \text{if } a \leq x < m \\ 1 - 2\left(\frac{x-b}{b-a}\right)^2, & \text{if } m \leq x < b \\ 1, & \text{if } x \geq b \end{cases}$$

```
In [5]: import matplotlib.pyplot as plt
import numpy as np

a = 20
b = 80
m = int((a+b)/2)
n = 50

plt.rcParams['text.usetex'] = True
x = np.arange(0,100,1)
y1 = x[:a]*0
y2 = 2*(((x[a:m]-a)/(b-a))**2)
y3 = 1-2*(((x[m:b]-b)/(b-a))**2)
y4 = np.ones(len(x[b:]))
y = np.concatenate([y1, y2, y3, y4])
line_1 = np.ones(len(x))
line_05 = np.ones(len(x))/2
y_m = np.linspace(0,1,len(x))
line_m = np.ones(len(x))*m
y_n = np.linspace(0,1,len(x))
line_n = np.ones(len(x))*n

fig = plt.figure()
ax = fig.add_subplot(1,1,1)
ax.set_title(r'Función de membresía S')
ax.set_xlabel(r"$x$")
ax.set_ylabel(r"$\mu(x)$")
ax.set_ylim(ymin=-0.1, ymax=1.1)
ax.set_ylim(bottom=0)
ax.set_xlim(xmin=-10, xmax=110)
ax.set_xlim(left=0)
ax.set_xticks([m])
ax.set_xticklabels([r'$\frac{a+b}{2}$'])
ax.set_yticks([0.0, 0.5, 1.0])
ax.spines[['right', 'top']].set_visible(False)
ax.plot(x, y, 'r', line_m, y_m, 'g--', x, line_1, 'b--', line_05, 'b--')
plt.show()
```



Transformaciones sobre conjuntos difusos

Existen algunas transformaciones útiles que pueden ser aplicadas sobre conjuntos difusos.

Normalización

Permite convertir un conjunto difuso subnormal a un conjunto normal.

$$\text{NORM}(F, x) = \frac{\mu_F(x)}{\text{height}(F)}$$

```
In [6]: import matplotlib.pyplot as plt
import numpy as np

m = 50
k = 0.005
a = 0.8

plt.rcParams['text.usetex'] = True
x = np.arange(0, 100, 1)
y = a*np.exp(-k*(x-m)**2)
y_norm = y/(np.max(y))
line_m = np.ones(len(x))*m
```


```

line_1 = np.ones(len(x))

fig = plt.figure()
ax = fig.add_subplot(1,1,1)
ax.set_xlabel(r"$x$")
ax.set_ylabel(r"$\mu_{\{F\}}(x)$")
ax.set_ylim(ymin=-0.1, ymax=1.1)
ax.set_ylim(bottom=0)
ax.set_xlim(xmin=-10, xmax=110)
ax.set_xlim(left=0)
ax.set_yticks([0.0, 1.0])
ax.set_xticks([])
ax.spines[['right', 'top']].set_visible(False)
ax.plot(x, y, 'r', x, y_norm, 'r--', x, line_1, 'b--')

plt.legend([r'$F$', r'$NORM(F)$'])
plt.show()

```



Dilatación

Operación que permite dilatar (aplanar) la función de membresía.

$$\text{DIL}(F, x) = (\mu_F(x))^{\frac{1}{2}}$$

```

In [7]: import matplotlib.pyplot as plt
import numpy as np

m = 50
k = 0.005

```

```


a = 1.0

plt.rcParams['text.usetex'] = True
x = np.arange(0,100,1)
y = a*np.exp(-k*(x-m)**2)
y_dil = np.sqrt(y)
line_m = np.ones(len(x))*m
line_l = np.ones(len(x))

fig = plt.figure()
ax = fig.add_subplot(1,1,1)
ax.set_xlabel(r"$x$")
ax.set_ylabel(r"$\mu_F(x)$")
ax.set_ylim(ymin=-0.1, ymax=1.1)
ax.set_ylim(bottom=0)
ax.set_xlim(xmin=-10, xmax=110)
ax.set_xlim(left=0)
ax.set_yticks([0.0, 1.0])
ax.set_xticks([])
ax.set_xticklabels([])
ax.spines[['right', 'top']].set_visible(False)
ax.plot(x, y, 'r', x, y_dil, 'r--', x, line_l, 'b--')

plt.legend([r'$F$', r'DIL$(F)$'])
plt.show()

```



Concentración

Operación que produce el efecto contrario a la dilatación.

$$\text{CON}(F, x) = (\mu_F(x))^2$$


```
In [8]: import matplotlib.pyplot as plt
import numpy as np

m = 50
k = 0.005
a = 1.0

plt.rcParams['text.usetex'] = True
x = np.arange(0, 100, 1)
y = a*np.exp(-k*(x-m)**2)
y_con = y**2
line_m = np.ones(len(x))*m
line_l = np.ones(len(x))

fig = plt.figure()
ax = fig.add_subplot(1, 1, 1)
ax.set_xlabel(r"$x$")
ax.set_ylabel(r"$\mu_{\{F\}}(x)$")
ax.set_ylim(ymin=-0.1, ymax=1.1)
ax.set_ylim(bottom=0)
ax.set_xlim(xmin=-10, xmax=110)
ax.set_xlim(left=0)
ax.set_yticks([0.0, 1.0])
ax.set_xticks([])
ax.set_xticklabels([])
ax.spines[['right', 'top']].set_visible(False)
ax.plot(x, y, 'r', x, y_con, 'r--', x, line_l, 'b--')

plt.legend([r'$F$', r'CON$(F)$'])
plt.show()
```



Intensificación de contraste

Reduce los valores de membresía menores de 0.5 y potencia valores mayores que 0.5.

$$\text{INF}(F, x) = \begin{cases} 2(\mu_F(x))^2, & \text{if } 0 \leq \mu_F(x) \leq 0.5 \\ 1 - 2(1 - \mu_F(x))^2, & \text{otherwise} \end{cases}$$

```
In [9]: import matplotlib.pyplot as plt
import numpy as np

m = 50
k = 0.005
a = 1.0

plt.rcParams['text.usetex'] = True
x = np.arange(0, 100, 1)
y = a*np.exp(-k*(x-m)**2)
y_inf = np.where(y<=0.5, 2*(y**2), 1-2*((1-y)**2))
line_m = np.ones(len(x))*m
line_l = np.ones(len(x))


fig = plt.figure()
ax = fig.add_subplot(1,1,1)
ax.set_xlabel(r"$x$")
ax.set_ylabel(r"$\mu_{\{F\}}(x)$")
ax.set_ylim(ymin=-0.1, ymax=1.1)
ax.set_ylim(bottom=0)
ax.set_xlim(xmin=-10, xmax=110)
```

```

ax.set_xlim(left=0)
ax.set_yticks([0.0, 1.0])
ax.set_xticks([])
ax.set_xticklabels([])
ax.spines[['right', 'top']].set_visible(False)
ax.plot(x, y, 'r', x, y_inf, 'r--', x, line_1, 'b--')

plt.legend([r'$F$', r'$INF(F)$'])
plt.show()

```



Difusión (fuzzification)

Produce el efecto contrario a la intensificación de contraste. Valores menores de 0.5 son potenciados y valores mayores a 0.5 son reducidos.

$$FUZZ(F, x) = \begin{cases} \left(\frac{\mu_F(x)}{2}\right)^{\frac{1}{2}}, & \text{if } 0 \leq \mu_F(x) \leq 0.5 \\ 1 - \left(\frac{1-\mu_F(x)}{2}\right)^{\frac{1}{2}}, & \text{otherwise} \end{cases}$$

```

In [10]: import matplotlib.pyplot as plt
import numpy as np

m = 50
k = 0.005
a = 1.0

plt.rcParams['text.usetex'] = True
x = np.arange(0, 100, 1)
y = a*np.exp(-k*(x-m)**2)

```


```

y_fuzz = np.where(y<=0.5, np.sqrt(y/2), 1-np.sqrt((1-y)/2))
line_m = np.ones(len(x))*m
line_l = np.ones(len(x))

fig = plt.figure()
ax = fig.add_subplot(1,1,1)
ax.set_xlabel(r"$x$")
ax.set_ylabel(r"$\mu_{\{F\}}(x)$")
ax.set_ylim(ymin=-0.1, ymax=1.1)
ax.set_ylim(bottom=0)
ax.set_xlim(xmin=-10, xmax=110)
ax.set_xlim(left=0)
ax.set_yticks([0.0, 1.0])
ax.set_xticks([])
ax.set_xticklabels([])
ax.spines[['right', 'top']].set_visible(False)
ax.plot(x, y, 'r', x, y_fuzz, 'r--', x, line_l, 'b--')

plt.legend([r'$F$', r'FUZZ$(F)$'])
plt.show()

```



Variables lingüísticas


Una **variable lingüística** es una variable cuyos valores no son números exactos, sino palabras o etiquetas que representan conceptos difusos, como *bajo*, *alto*, *muy alto*, *aproximadamente medio*, etc.

- Descripciones lingüísticas pueden en ocasiones ser traducidas a transformaciones sobre funciones de membresía.
- Ej: Gráfico para función de membresía `alto` y `muy alto`.

```
In [11]: import matplotlib.pyplot as plt
import numpy as np

plt.rcParams['text.usetex'] = True
x = np.arange(0,100,1)
y1 = x[0:30]*0
y2 = (x[30:70]-30)/40
y3 = x[70:]*0 + 1
y = np.concatenate([y1, y2, y3])
y_vtall = y**2

fig = plt.figure()
ax = fig.add_subplot(1,1,1)
ax.set_title(r'Alto vs Muy Alto')
ax.set_ylim(ymin=-0.1, ymax=1.1)
ax.set_ylim(bottom=0)
ax.set_xlim(xmin=-10, xmax=110)
ax.set_xlim(left=0)
ax.set_yticks([])
ax.set_yticklabels([])
ax.set_xticks([])
ax.set_xticklabels([])
ax.spines[['right', 'top']].set_visible(False)
ax.plot(x, y, 'r', x, y_vtall, 'r--')
plt.legend([r'Alto / $F$', r'\textbf{Muy} Alto / CON$(F)$'])
plt.grid()
plt.show()
```



Estas etiquetas pueden traducirse en transformaciones sobre las funciones de membresía:

- **Muy A → Concentración**
Se eleva la función de membresía al cuadrado, reduciendo valores menores de 1 y reforzando los más altos.
- **Más o menos A → Dilatación**
Se aplica raíz cuadrada a la función de membresía, aplanando la curva y aumentando valores bajos.
- **Extremadamente A → Intensificación**
Disminuye valores menores a 0.5 y refuerza valores mayores a 0.5.
- **No A → Complemento**
Se aplica el operador clásico de complemento:
- **A o B → Unión**
Se usa el máximo entre las funciones de membresía:
- **A y B → Intersección**
Se usa el mínimo entre las funciones de membresía:

De esta forma, las **descripciones lingüísticas** en un sistema difuso se traducen directamente a **operaciones matemáticas**, lo que permite construir reglas de

inferencia como:

“Si la temperatura es muy alta y la humedad es baja, entonces el riesgo de incendio es alto”.

Operaciones en conjuntos difusos

Una gran cantidad de operaciones de conjuntos clásicas pueden ser aplicadas directamente sobre conjuntos difusos.

La diferencia es que ahora los resultados no son solo “sí o no”, sino que consideran los **grados de pertenencia**.

Estas operaciones permiten combinar, comparar o modificar conjuntos difusos para representar situaciones con incertidumbre.

Unión ($P \cup Q$)

$$\mu_{P \cup Q}(x) = \max\{\mu_P(x), \mu_Q(x)\}, \forall x \in U$$

Intersección ($P \cap Q$)

$$\mu_{P \cap Q}(x) = \min\{\mu_P(x), \mu_Q(x)\}, \forall x \in U$$

Complemento ($\bar{P}$)

$$\mu_{\bar{P}}(x) = 1 - \mu_P(x), \forall x \in U$$

Igualdad ($P = Q$)

$$P = Q \Leftrightarrow \forall x \in U, \mu_P(x) = \mu_Q(x)$$

Inclusión ($P \subseteq Q$)

$$P \subseteq Q \Leftrightarrow \forall x \in U, \mu_P(x) \leq \mu_Q(x)$$

Producto ($P \cdot Q$)

$$\mu_{P \cdot Q}(x) = \{\mu_P(x) \cdot \mu_Q(x)\}, \forall x \in U$$

Diferencia ($P - Q$)

$$P - Q = P \cap \bar{Q}$$

Relaciones entre conjuntos difusos

- Así como existen las relaciones entre conjuntos tradicionales, también es posible definir relaciones entre conjuntos difusos. Recordatorios sobre relaciones entre conjuntos tradicionales en el [Anexo 2](#).

Producto Cartesiano difuso ($A \times B$)

Sea A y B dos conjuntos difusos sobre dos conjuntos de tradicionales X e Y , se denota el producto cartesiano entre A y B como $A \times B \subseteq X \times Y$ donde

$$\mu_{A \times B}(a, b) = \min \mu_A(a), \mu_B(b); \forall a \in X, \forall b \in Y$$

Ejemplo

Considere los conjuntos $X = \{m, n\}$ e $Y = \{p, q, r\}$, y los conjuntos difusos A y B definidos sobre ellos como

$$A = \frac{0.3}{m} + \frac{0.7}{n}$$

$$B = \frac{0.5}{p} + \frac{0.1}{q} + \frac{0.8}{r}$$

La función de membresía del producto cartesiano $A \times B$ para algunos de sus pares de elementos son los siguientes:

$$\mu_{A \times B}(m, p) = \min\{0.3, 0.5\} = 0.3$$

$$\mu_{A \times B}(m, q) = \min\{0.3, 0.1\} = 0.1$$

La matriz de relación de dicho producto cartesiano sería la siguiente

$$T_{A \times B} = \begin{bmatrix} 0.3 & 0.1 & 0.3 \\ 0.5 & 0.1 & 0.7 \end{bmatrix}$$

Relaciones difusas

Se define una relación R entre dos conjuntos difusos A y B como un **subconjunto** del producto cartesiano $R \subseteq A \times B$

Ejemplo

Considerando los conjuntos definidos en el ejemplo anterior de producto cartesiano sobre conjuntos difusos, la siguiente matriz de relación define una relación **válida** entre los conjuntos difusos A y B .

$$T_R = \begin{bmatrix} 0.2 & 0.1 & 0.1 \\ 0.3 & 0.0 & 0.5 \end{bmatrix}$$

Operaciones en relaciones difusas

- La mayoría de operaciones sobre relaciones en conjuntos tradicionales son válidas sobre conjuntos difusos.
- Entre estas operaciones se encuentra la *Unión*, *Intersección*, *Complemento* e *Inclusión (subconjunto)*, definidas en el [Anexo2](#).
- También existen modificaciones o generalizaciones de operaciones definidas en los conjuntos tradicionales.

Composición de Relaciones

1. En conjuntos tradicionales

Dado tres conjuntos clásicos A, B, C :

- Una **relación** R entre A y B es un subconjunto del producto cartesiano:

$$R \subseteq A \times B$$

- Una **relación** S entre B y C es un subconjunto:

$$S \subseteq B \times C$$

La **composición** de R y S , denotada $R \circ S$, se define como:

$$R \circ S = \{(a, c) \in A \times C \mid \exists b \in B : (a, b) \in R \wedge (b, c) \in S\}$$

Es decir, a se relaciona con c si existe un b intermedio que conecta ambos.

Ejemplo clásico

$$A = \{1, 2\}, B = \{x, y\}, C = \{\alpha, \beta\}$$

$$R = \{(1, x), (2, y)\}$$

$$S = \{(x, \alpha), (y, \beta)\}$$

Entonces:

$$R \circ S = \{(1, \alpha), (2, \beta)\}$$

Composición max-min

- Corresponde a la generalización de la composición de conjuntos tradicionales para conjuntos difusos.
- Considere los conjuntos tradicionales A , B y C y las relaciones difusas R y S sobre $A \times B$ y $B \times C$ respectivamente, se define la composición max-min de R en S (denotado como $R \circ S$) como la relación sobre $A \times C$ tal que:

$$(R \circ S)(x, z) = \max_{y \in B} \{ \min \{ R(x, y), S(y, z) \} \}$$

Sentido de la composición max-min

En conjuntos difusos, cada relación se mide con un grado en $[0, 1]$.

La composición se define como:

$$(R \circ S)(x, z) = \max_{y \in B} \{ \min(R(x, y), S(y, z)) \}$$

- El **mínimo** refleja que la fuerza de un camino $x \rightarrow y \rightarrow z$ depende de su eslabón más débil.
- El **máximo** refleja que, si existen varios caminos, se conserva el más fuerte de ellos.

Así, la composición max-min es la extensión natural de la composición clásica al caso difuso, manteniendo la idea de conexión a través de un intermediario.

Ejemplo

Considere los grupos $A = \{a, b, c\}$, $B = \{x, y\}$ y $C = \{p, q, r\}$ y las siguientes relaciones R y S sobre $A \times B$ y $B \times C$:

$$T_R = \begin{bmatrix} 0.3 & 0.7 \\ 0.9 & 0.4 \\ 0.2 & 0.5 \end{bmatrix}$$

$$T_S = \begin{bmatrix} 0.4 & 0.1 & 0.8 \\ 0.3 & 0.7 & 0.6 \end{bmatrix}$$

Calculando la *composición max-min* para algunos elementos

$$\begin{aligned} (R \circ S)(a, p) &= \max_{i \in B} \{ \min \{ R(a, i), S(i, p) \} \} \\ &= \max \{ \min(R(a, x), S(x, p)), \min(R(a, y), S(y, p)) \} \\ &= \max \{ \min(0.3, 0.4), \min(0.7, 0.3) \} \\ &= \max \{ 0.3, 0.3 \} \\ &= 0.3 \end{aligned} \tag{1}$$

$$\begin{aligned}
(R \circ S)(a, q) &= \max_{i \in B} \{ \min \{ R(a, i), S(i, q) \} \} \\
&= \max \{ \min(R(a, x), S(x, q)), \min(R(a, y), S(y, q)) \} \\
&= \max \{ \min(0.3, 0.1), \min(0.7, 0.7) \} \\
&= \max \{ 0.1, 0.7 \} \\
&= 0.7
\end{aligned} \tag{2}$$

Representado la relación completa a través de su matriz de relación:

$$T_{R \circ S} = \begin{bmatrix} 0.3 & 0.7 & 0.6 \\ 0.4 & 0.4 & 0.8 \\ 0.3 & 0.5 & 0.5 \end{bmatrix}$$

Principio de Extensión

El **principio de extensión** de Zadeh es el mecanismo que permite **extender funciones clásicas** (definidas sobre conjuntos tradicionales) al contexto de **conjuntos difusos**.

En otras palabras, nos dice cómo calcular la **imagen difusa** de un conjunto difuso bajo una función.

Gracias a este principio podemos aplicar operaciones comunes (suma, máximo, producto, etc.) a conjuntos difusos y obtener un nuevo conjunto difuso como resultado.

- En conjuntos clásicos:
Si tenemos una función $f : U \rightarrow V$ y un subconjunto $A \subseteq U$, su imagen es simplemente:

$$f(A) = \{f(u) : u \in A\}.$$

- En conjuntos difusos:
Como cada elemento $u \in U$ tiene un **grado de pertenencia** $\mu_A(u)$, necesitamos definir cómo trasladar esos grados a los elementos de V que son imágenes bajo la función.

El principio de extensión hace justamente eso: construye un nuevo conjunto difuso $B \subseteq V$ cuya función de pertenencia depende de las de los conjuntos difusos originales.

Definición formal

- Considere la función

$$f : U_1 \times U_2 \times \cdots \times U_n \rightarrow V$$

donde los conjuntos U_i y V son conjuntos tradicionales.

- Si existe un elemento $v \in V$ tal que $f(u_1, u_2, \dots, u_n) = v$ se dice que:
 - v es la **imagen** del punto $(u_1, u_2, \dots, u_n)$, definido por

$$f(u_1, u_2, \dots, u_n) = v$$

- $(u_1, u_2, \dots, u_n)$ es la **pre-imagen** de v , definido por

$$(u_1, u_2, \dots, u_n) \in f^{-1}(v)$$

- Luego, considere los conjuntos difusos $A_1, A_2, \dots, A_n$ en los universos $U_1, U_2, \dots, U_n$ respectivamente.
Dada la función f definida anteriormente, es posible construir un conjunto difuso B en V de la siguiente manera:

$$\mu_B(v) = \begin{cases} 0, \\ \max \left\{ \min \{ \mu_{A_1}(u_1), \mu_{A_2}(u_2), \dots, \mu_{A_n}(u_n) \} : f(u_1, u_2, \dots, u_n) = v \right\}, \end{cases}$$

Ejemplo

Sea la función:

$$f : U_1 \times U_2 \rightarrow V, \quad f(u_1, u_2) = u_1 + u_2$$

con:

- $U_1 = U_2 = \{0, 1\}$
- $V = \{0, 1, 2\}$

Definimos los conjuntos difusos:

$$A_1 = \frac{0.8}{0} + \frac{0.5}{1}, \quad A_2 = \frac{0.6}{0} + \frac{1.0}{1}.$$

Ahora aplicamos el principio de extensión:

1. Para $v = 0$: la única preimagen es $(0, 0)$.

$$\mu_B(0) = \min(\mu_{A_1}(0), \mu_{A_2}(0)) = \min(0.8, 0.6) = 0.6$$

2. Para $v = 1$: las preimágenes son $(0, 1), (1, 0)$.

$$\mu_B(1) = \max\{\min(0.8, 1.0), \min(0.5, 0.6)\} = \max\{0.8, 0.5\} = 0.8$$

3. Para $v = 2$: la única preimagen es $(1, 1)$.

$$\mu_B(2) = \min(0.5, 1.0) = 0.5$$

Resultado final

El conjunto difuso imagen es:

$$B = \frac{0.6}{0} + \frac{0.8}{1} + \frac{0.5}{2}$$

B es el **conjunto difuso imagen**: muestra con qué grado de pertenencia cada $v \in V$ puede ser resultado de la función f aplicada a los conjuntos difusos de entrada.

Lógica Difusa (Fuzzy Logic)

A diferencia de lo que ocurre en la lógica de conjuntos tradicional ([Anexo 3](#)), en lógica difusa se admite la posibilidad de diferentes valores de verdad o falsedad entre la verdad absoluta y la falsedad absoluta.

Valores de verdad difusos

Mientras los valores de verdad para conjuntos tradicionales solo pueden ser verdadero/1 o falso/0, los valores de verdad difusos incluyen múltiples valores entre 0 y 1 incluyendo estos últimos.

Ejemplos Algunos valores lingüísticos pueden ser asociados a valores numéricos como se muestra en la tabla siguiente

Valor lingüístico	Valores
Completamente Falso	0.0
Parcialmente Falso	0.25
Ni Verdadero ni Falso	0.5
Verdadero y Falso	0.5
Parcialmente Verdadero	0.75
Completamente Verdadero	1.0

Proposiciones difusas

Son aquellas proposiciones que pueden tener valores de verdad difusos. Sea p una proposición difusa, se define $\tau(p)$ como su valor de verdad difuso, donde

$$0 \leq \tau(p) \leq 1$$

Ejemplos

Proposición	Valor lingüístico	Valor numérico
$\sqrt{2}$ es un número racional	Completamente Falso	0.0
Él es millonario	Parcialmente Falso	0.4
La Tierra es Redonda	Casi completamente Verdadero	0.97
El único número primo y par es 2	Completamente Verdadero	1.0

Operaciones de lógica difusa

Operaciones básicas de lógica de conjuntos tradicional tiene su equivalente difuso según aparece en la siguiente tabla

#	Operation	Symbol	Usage	Definition
1	<i>disjunction</i>	+	$P + Q$	$\tau(P + Q) = \max\{\tau(P), \tau(Q)\}$
2	<i>conjunction</i>	•	$P \bullet Q$	$\tau(P \bullet Q) = \min\{\tau(P), \tau(Q)\}$
3	<i>negation</i>	$\neg$	$\neg P$	$\tau(\neg P) = 1 - \tau(P)$
4	<i>implication</i>	$\rightarrow$	$P \rightarrow Q$	$\tau(P \rightarrow Q) = \max\{1 - \tau(P), \tau(Q)\}$

Valores de verdad difusos

- Los valores de verdad en lógica difusa equivalen a los valores de membresía de un elemento a un conjunto difuso.
- Considere el conjunto F sobre el universo U , y un elemento $x \in U$. El valor de verdad de la proposición $p = 'x \text{ es un miembro de } F'$ corresponde simplemente al valor de membresía de x en F . Es decir $\tau(p) = \mu_F(x)$.
- Debido a esto último, la lógica difusa y la teoría de conjuntos difusos son sistemas isomórficos.

Valores de verdad difusos y variables lingüísticas

- Es posible encontrar el valor de verdad $\tau(s)$ de una proposición difusa $s = 'x \text{ es } P'$, donde P es un valor difuso de una variable lingüística L , de la siguiente manera:
 - Evaluar L para x
 - Encontrar la membresía de $L(x)$ en P . Es decir, $\mu_P(L(x))$.
 - $\tau(s) = \mu_P(L(x))$

Ejemplo


Considere la proposición difusa $p = \text{'Anita es joven'}$. **Joven** representa una variable lingüística de la variable **edad**. Otros valores posibles son **muy joven**, **mediana edad**, **anciano**, **muy anciano**, etc. Cada uno de estos valores corresponde a un conjunto difuso en el universo **edad**. Considere la función de membresía a **joven** de la siguiente figura:

```
In [12]: import matplotlib.pyplot as plt
import numpy as np

a = 10
m = 20
b = 30

plt.rcParams['text.usetex'] = True
x = np.arange(0,50,1)
y1 = x[:a]*0
y2 = (x[a:m]-a)/(m-a)
y3 = (b-x[m:b])/(b-m)
y4 = x[b:]*0
y = np.concatenate([y1, y2, y3, y4])
line_05 = 0.5*np.ones(len(x))
y_m = np.linspace(0,1,len(x))
line_m = np.ones(len(x))*25
line_1 = np.ones(len(x))

fig = plt.figure()
ax = fig.add_subplot(1,1,1)
ax.set_xlabel(r"Edad en años")
ax.set_ylabel(r"$\mu_{\text{joven}}$")
ax.set_ylim(ymin=-0.1, ymax=1.1)
ax.set_ylim(bottom=0)
ax.set_xlim(xmin=-10, xmax=45)
ax.set_xlim(left=0)
ax.set_yticks([0.0, 0.5, 1.0])
ax.spines[['right', 'top']].set_visible(False)
ax.plot(x, y, 'r', x, line_1, 'b--', line_m, y_m, 'g--', x, line_05, 'g--',)
plt.show()
```



Suponiendo que Anita tiene 25 años, para encontrar el valor de verdad, se debe evaluar la sentencia de la siguiente manera:

1. $\text{edad}(\text{Anita}) = 25$
2. $\mu_{joven}(\text{edad}(\text{Anita})) = \mu_{joven}(25) = 0.5$
3. Valor de verdad de $p = \text{'Anita es joven'}$ es $\tau(p) = \mu_{joven}(25) = 0.5$

Reglas difusas

- Corresponden a reglas que permiten modelar la relación existente entre datos de entrada y datos de salida normalmente expresados en términos lingüísticos.
- Son la base fundamental para los sistemas de inferencias difusos.

If-Then difuso

- Dadas dos proposiciones difusas atómicas (indivisibles) p y q , se define una regla difusa R tal que

If p then q

- Si cada proposición es del tipo p es A , denotada como $A(x)$, entonces la regla difusa queda expresada como

$R : \text{If 'x es A' then 'y es B'}$

o expresada simbólicamente como

$$R : A(x) \rightarrow B(y)$$

donde A y B son conjuntos difusos

- Expresando esta regla como una relación difusa, tenemos:

$$R(x, y) = \tau[A(x) \rightarrow B(y)]$$

- El cómo se calcule el valor, dependerá de cómo se interpreta dicha operación.
Algunas interpretaciones populares:

Interpretación de Mamdani

$$\begin{aligned} R(x, y) &= \tau[A(x) \rightarrow B(y)] \\ &= \min[\tau(A(x)), \tau(B(y))] = \min[\mu_A(x), \mu_B(y)] \end{aligned} \quad (3)$$

donde la relación representa $R = A \bullet B$

- En esta interpretación, el consecuente queda **recortado** por el grado de verdad del antecedente. Es la más usada en sistemas de control difuso por su simplicidad.

Interpretación de Zadeh (composición Max-Min)

$$\begin{aligned} R(x, y) &= \tau[A(x) \rightarrow B(y)] \\ &= \max[\min\{\mu_A(x), \mu_B(y)\}, 1 - \mu_A(x)] \end{aligned} \quad (4)$$

donde la relación representa $R = (A \times B) \cup (\bar{A} \times V)$, siendo V el conjunto universo en el cual está contenido B .

- Aquí la regla refleja la **implicación lógica clásica adaptada al caso difuso**, permitiendo que incluso cuando $A(x)$ es bajo, la relación pueda seguir teniendo un grado alto.

If-Then-Else difuso

- Regla difusa definida como

$$R : \text{If } 'x \text{ es } A' \text{ then } 'y \text{ es } B' \text{ Else } 'y \text{ es } C'$$

Interpretación

$$R(x, y) = \max[\min\{\mu_A(x), \mu_B(y)\}, \min\{1 - \mu_A(x), \mu_C(y)\}]$$

donde la relación representa $R = (A \times B) \cup (\bar{A} \times C)$.

En esta forma, si x pertenece a A con cierto grado, la conclusión se asocia a B .

Si x **no pertenece** a A (es decir, $\bar{A}$), la conclusión se asocia a C .

La regla permite modelar **decisiones con alternativas**, de modo que siempre haya una salida (o B o C) dependiendo del grado de pertenencia del antecedente.

Base de reglas difusas (Fuzzy Rule Base)

- Al momento de tomar una decisión sobre un problema, nos encontraremos que muchos de ellos poseen múltiples reglas, las cuales define la base de conocimiento del problema. Esto es lo que se conoce como **base de reglas difusas**.
- Una base de reglas difusas puede ser expresada como una secuencia de reglas.

Ejemplo

- Si la temperatura es fría, entonces el calentador está en alto.
- Si la temperatura es fresca, entonces el calentador está en bajo.
- Si la temperatura es agradable, el calentador está apagado.
- Si la temperatura es tibia, el enfriador está en bajo.
- Si la temperatura es calurosa, el enfriador está en alto.

Razonamiento difuso/lógica proposicional difusa

- Proceso para obtención de nuevas proposiciones difusas a partir de proposiciones difusas ya existentes.
- Ejemplo: Obtención de una conclusión a partir de premisas

Modus Ponens generalizado

- El Modus Ponens generalizado es similar al [Modus Ponens tradicional](#), pero cuyas premisas corresponden a proposiciones difusas y la conclusión puede ser inexacta.
- El Modus Ponens generalizado se representa de la siguiente manera

Premisa 1	Si x es A , entonces y es B .
Premisa 2	x es A_1 .
Conclusión	Por lo tanto, y es B_1.

donde A_1 y B_1 son versiones modificadas de A y B respectivamente.

Ejemplo

Premisa 1 Si este auto es caro, entonces es cómodo.

Premisa 2 El auto es más o menos caro.

Conclusión Por lo tanto, el auto es más o menos cómodo.

El Modus ponens generalizado también es conocido como *inferencia difusa*. Zadeh interpretó esta inferencia difusa en términos de una composición Max-Min entre conjuntos difusos. Sea A y A_1 , conjuntos difusos sobre el universo U , y B y B_1 conjuntos difusos sobre el universo V , se puede obtener el valor de verdad y es B_1 en términos de las funciones de membresía de los conjuntos difusos de la siguiente manera:

$$\tau(y \text{ es } B_1) = \mu_{B_1}(y) = \max_{x \in U} [\min\{\mu_{A_1}(x), \mu_R(x, y)\}]$$

donde R representa la relación correspondiente a la regla " Si ' x es A ', entonces ' y es B ' ".

Modus Tollens generalizado

- Al igual que en el Modus Ponens generalizado, el Modus Tollens generalizado se basa en el [Modus Tollens tradicional](#), pero con la posibilidad de incluir premisas difusas y resultados inexactos.
- El Modus Tollens generalizado se representa de la siguiente manera

Premisa 1	Si x es A , entonces y es B .
Premisa 2	y es B_1 .
Conclusión	Por lo tanto, x es A_1.

donde A_1 y B_1 son versiones modificadas de A y B respectivamente.

Ejemplo

Premisa 1 Si este auto es caro, entonces es cómodo.

Premisa 2 El auto es más o menos cómodo.

Conclusión Por lo tanto, el auto es más o menos caro.


De manera similar al caso anterior, también es posible calcular su valor de verdad utilizando la siguiente fórmula

$$\tau(x \text{ es } A_1) = \mu_{A_1}(x) = \max_{y \in V} [\min\{\mu_{B_1}(y), \mu_R(x, y)\}]$$


donde R representa la relation asociada a la regla " Si ' x es A ', entonces ' y es B ' ".

Sistemas de Inferencia Difusos

- Se habla de Sistemas de Inferencia Difusos (FIS - Fuzzy Inference Systems), a aquellos que transforman una entrada a una salida generada utilizando lógica difusa.
- Este tipo de sistemas son utilizados como la base para los procesos de toma de decisiones.
- El proceso realizado por un sistema de inferencia difuso es conocido como mecanismo de inferencia difusa o, simplemente, inferencia difusa.
- A continuación un esquema general de un sistema de inferencia difuso.



- El sistema de inferencia difuso más común es el propuesto por Ebrahim Mamdani en 1975. Este sistema está compuesto por 5 etapas:
 1. Difusión (fuzzication) de las variables de entrada.
 2. Aplicación de operadores difusos en los antecedentes de las reglas.
 3. Evaluación de las reglas difusas.
 4. Combinación de conjuntos difusos a través de sus reglas.
 5. Desdifusión (defuzzification) del conjunto difuso resultante




Ejemplo Considere un peatón intentando cruzar la calle mientras un auto se acerca. ¿A qué ritmo debería cruzar?

La base de reglas difusas para este problema sería:


- Si el auto está lejos y se acerca a baja velocidad, entonces el peatón puede cruzar tranquilamente.
- Si el auto está lejos, pero se acerca a alta velocidad, debería cruzar más rápido, pero sin prisas.
- Si el auto está muy cerca o se acerca a alta velocidad, debería cruzar rápidamente.

En este caso, el sistema de inferencia difuso se vería como en el siguiente diagrama



1. Fuzzification

- Las entradas para un sistema de inferencia difuso son valores tradicionales correspondientes a ciertos parámetros de entrada (ej. Distancia del auto en rango 0-10, o velocidad del auto en rango 0-10)
- Estos parámetros se relacionan respecto a sus valores lingüísticos dados en las base de reglas difusas
 1. El auto está lejos.
 2. El auto está cerca.
 3. El auto se acerca rápido.
 4. El auto se acerca lento.
- El proceso de fuzzification determina por cada parámetro de entrada su **grado de pertenencia** a los conjuntos difusos definidos en las reglas utilizando las funciones de membresía.
- Ejemplo de fuzzification de la distancia del auto respecto al conjunto difuso **muy lejos**. Para una distancia 7 en el rango de 0-10, la función de membresía retorna un 0.5 como se muestra a continuación




2. Aplicación de operadores difusos en los antecedentes de las reglas

- Se utilizan los operadores difusos para evaluar los antecedentes de nuestra base de reglas difusas.
- En nuestro ejemplo, las partes que componen las reglas R_1 y R_2 se encuentran unidas con un *AND*, mientras que la regla R_3 se encuentra unida a través de un operador *OR*.
- En cada caso, es necesario evaluar el valor de verdad de los antecedentes entregados según la regla.
- Para ello se utilizan las operaciones de lógica difusa *AND* (disyunción) u *OR* (conjunción).
- Además de las implementaciones anteriormente vistas para el *AND* y el *OR* difuso, también existen otras implementaciones para estos.

#	Operator	Method	
1	AND	(min)	$\tau(P.AND.Q) = \min [\tau(P), \tau(Q)]$
		(product)	$\tau(P.AND.Q) = \tau(P) \times \tau(Q)$
2	OR	(max)	$\tau(P.OR.Q) = \max [\tau(P), \tau(Q)]$
		(probabilistic OR)	$\tau(P.OR.Q) = \tau(P) + \tau(Q) - \tau(P) \times \tau(Q)$


- Para el ejemplo anterior, considerando un valor de distancia 7 (escala 0-10) y velocidad 3 (escala 0-10), la evaluación del antecedente para la regla R_1 "El auto está lejos Y se aproxima lentamente", se obtiene según se indica en la siguiente figura



En este caso el, aplicando la operación AND con el operador mínimo, se obtiene un valor de 0.5 para el antecedente de la regla R_1 .



3. Evaluación de las reglas difusas

- Luego de obtenidos los valores de los antecedentes, se debe evaluar cada una de las reglas difusas.
- Para ello se utilizan la evaluación de las reglas de implicación (If-Then, If-Then-Else) vistas anteriormente, según la interpretación que se desee utilizar.
- La función de membresía del consecuente se ve modificada por el valor obtenido en el antecedente.
- En nuestro ejemplo, utilizando la interpretación de Mamdani para la operación de implicación, la forma de la función de membresía para el consecuente de la regla R_1 quedaría como se muestra en la siguiente figura




4. Combinación de conjuntos difusos a través de sus reglas

- Una vez obtenidos los resultados para cada regla individual, basta con combinar los resultados de las diferentes reglas de la base del sistema.
- Existen diferentes métodos para la agregación de conjuntos, tales como la operación *máx*, que calcula el máximo entre los diferentes inputs, o la operación *suma*, que calcula la suma algebraica de los conjuntos.



5. Desdifusión (defuzzification) del conjunto difuso resultante

- De la etapa anterior, independiente de la operación utilizada para agregación, el resultado será un conjunto difuso.
- En nuestro ejemplo, quedaría como se muestra a continuación




- Sin embargo, esto no sirve como un resultado de la inferencia, pues debe entregarse *un valor*.
- Para ello se debe hacer un proceso de defuzzification, es decir, obtener un único valor a partir del conjunto difuso obtenido.
- Existen múltiples métodos de defuzzification, tales como
 1. Método del centroide
 2. Método del centro de sumas (Centre-of-Sums CoS)
 3. Método de la Media de Máxima (Mean-of-Maxima MoM)

Método del centroide

- En este método, el conjunto difuso de salida debe ser calculado a través de la operación *máx*.
- Una vez obtenido, se calcula **el centro de masa del área de dicho conjunto**.

Ejemplo



- Este se calcula dependiendo de la naturaleza del conjunto difuso obtenido
 - Para funciones de membresía discreta

$$x_{\text{centroid}} = \frac{\sum_{i=1}^n x_i \times \mu(x_i)}{\sum_{i=1}^n \mu(x_i)}$$

- Para funciones de membresía continuas


$$x_{\text{centroid}} = \frac{\int_a^b x \mu(x) dx}{\int_a^b \mu(x) dx}$$

donde $[a, b]$ es el dominio de x

Centre-of-Sums CoS

- Es idéntico al método del centroide, sin embargo considera el conjunto de salida a partir de la operación *suma* en vez de la operación *máx*.


Ejemplo




Mean-of-Maxima MoM

- Método simple para defuzzification.
- En este se obtiene el mayor grado de membresía entre todos los conjuntos difusos como valor de salida.
- En caso de haber múltiples elementos con valor de membresía máximo, se calcula el promedio entre ellos.

Ejemplo




Para nuestro ejemplo del automóvil, el resultado final se vería como se muestra en la figura



Controladores Difusos


- Corresponden a sistemas de inferencia difusos que utilizan descripciones difusas lingüísticas para controlar procesos físicos.
- Un controlador difuso básico consta de tres etapas: Etapa de entrada, etapa procesamiento y etapa de salida



- La **etapa de entrada** se alimenta de la lectura de sensores o elementos similares y se mapean su membresía a los conjuntos difusos correspondientes (difusión/fuzzification).
- La **etapa de procesamiento** utiliza una base de reglas difusas para obtener los conjuntos difusos de los consecuentes.

- La **etapa de salida** corresponde a la etapa de desdifusión/defuzzification, utilizando alguna de las técnicas vistas anteriormente.

A continuación se muestra un diagrama de bloques de cómo funcionaría un controlador difuso.



Anexo 1: Teoría de conjuntos clásica

Definición de conjunto

Colección de elementos no repetidos y sin un orden determinado.

Ejemplo (notaciones de conjuntos)

$$\begin{aligned}
 A &= \{\text{piedra, papel, tijera}\} \rightarrow \text{Enumeración} \\
 B &= \{n \in \mathbb{Z} \mid n \text{ es par}\} \rightarrow \text{Descripción}
 \end{aligned}
 \tag{5}$$

Cardinalidad

Número de elementos presente en un conjunto

Ejemplo

$$|A| = 3; |B| = \infty \tag{6}$$

Conjunto nulo/vacío (ϕ)

Conjunto sin elementos

$$|\phi| = 0 \quad (7)$$

Conjunto Universo (U)

Conjunto de todos los elementos posibles en un contexto

Subconjunto ($\subseteq$)

Se define un conjunto T como subconjunto ($\subseteq$) de un conjunto S si

$$\forall x, x \in T \Rightarrow x \in S$$

Igualda de conjuntos ($=$)

Dos conjuntos T y S son iguales si $T \subseteq S$ y $S \subseteq T$

Conjunto Potencia

Conjunto de todos los subconjuntos a partir de un conjunto inicial

Ejemplo

$$P(A) = \{\phi, \{\text{piedra}\}, \{\text{papel}\}, \{\text{tijera}\}, \{\text{piedra, papel}\}, \{\text{piedra, tijera}\}, \{\text{pap}$$



Operaciones de conjuntos

Dados los conjuntos genéricos P y Q , se definen las siguientes operaciones:

Unión ($\cup$)

$$P \cup Q = \{x \mid x \in P \text{ or } x \in Q\}$$

Intersección ($\cap$)

$$P \cap Q = \{x \mid x \in P \text{ and } x \in Q\}$$

Complemento ($\bar{P}$)

$$\bar{P} = \{x \mid x \notin P\}$$

Diferencia entre conjuntos ($-$)

$$\begin{aligned} P - Q &= \{x \mid x \in P \text{ and } x \notin Q\} \\ P - Q &= P \cap \bar{Q} \end{aligned} \tag{9}$$

Diferencia Simétrica ($\oplus$)

$$\begin{aligned} P \oplus Q &= \{x \mid (x \in P \text{ and } x \notin Q) \text{ or } (x \in Q \text{ and } x \notin P)\} \\ P \oplus Q &= (P - Q) \cup (Q - P) \\ P \oplus Q &= (P \cap \bar{Q}) \cup (\bar{P} \cap Q) \end{aligned} \tag{10}$$

Producto cartesiano ($\times$)

$$P \times Q = \{(x, y) \mid x \in P \text{ and } y \in Q\}$$

Propiedades de conjuntos

Idempotencia

$$\begin{aligned} A \cup A &= A \\ A \cap A &= A \end{aligned} \tag{11}$$

Conmutatividad

$$\begin{aligned} A \cup B &= B \cup A \\ A \cap B &= B \cap A \\ A \oplus B &= B \oplus A \end{aligned} \tag{12}$$

Asociatividad

$$\begin{aligned} A \cup (B \cup C) &= (A \cup B) \cup C \\ A \cap (B \cap C) &= (A \cap B) \cap C \\ A \oplus (B \oplus C) &= (A \oplus B) \oplus C \end{aligned} \tag{13}$$

Distributividad

$$\begin{aligned} A \cup (B \cap C) &= (A \cup B) \cap (A \cup C) \\ (A \cup B) \cap C &= (A \cap C) \cup (B \cap C) \\ A \cap (B \cup C) &= (A \cap B) \cup (A \cap C) \\ (A \cap B) \cup C &= (A \cup C) \cap (B \cup C) \end{aligned} \tag{14}$$

Ley de Morgan

$$\begin{aligned}\overline{(A \cap B)} &= \overline{A} \cup \overline{B} \\ \overline{(A \cup B)} &= \overline{A} \cap \overline{B}\end{aligned}\tag{15}$$

Identidad

$$\begin{aligned}A \cup \phi &= \phi \cup A = A \\ A \cap \phi &= \phi \cap A = \phi \\ A \cup U &= U \cup A = U \\ A \cap U &= U \cap A = U\end{aligned}\tag{16}$$

Involución

$$\overline{(\overline{A})} = A$$

Ley del complemento

$$\begin{aligned}A \cup \overline{A} &= U \\ A \cap \overline{A} &= \phi \\ \overline{\overline{U}} &= \phi \\ \overline{\overline{\phi}} &= U\end{aligned}\tag{17}$$

Absorción

$$\begin{aligned}A \cup (A \cap B) &= A \\ A \cap (A \cup B) &= A\end{aligned}\tag{18}$$

Anexo 2: Relaciones de conjuntos clásicas

Relaciones entre conjuntos

- Considere los conjuntos tradicionales A y B , y su producto cartesiano definido como

$$A \times B = \{(a, b) \mid a \in A, \text{ and } b \in B\}$$

se define una relación R entre los conjuntos A y B como un subconjunto del producto cartesiano entre los conjuntos A y B . Es decir,

$$R \subseteq A \times B$$

Esta relación puede ser representada con una *matriz de relación*. Los elementos de esta matriz se definen de la siguiente manera:

$$T_{ij} = \begin{cases} 1, & \text{if } (a_i, b_j) \in R \\ 0, & \text{otherwise} \end{cases}$$

, donde i y j representan las posiciones por filas y columnas respectivamente, mientras que a y b representan elementos pertenecientes a los grupos A y B .

Ejemplo

- Considere los conjuntos $A = \{1, 2, 3\}$, $B = \{1, 2, 3, 4\}$ y la relación entre ambos conjuntos definida como $R = \{(a, b) \mid b = a + 1, a \in A, \text{ and } b \in B\}$, la matriz de relación definida para R es la siguiente:

$$T_R = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}$$

Operaciones sobre relaciones entre conjuntos

Existen diversas operaciones sobre las relaciones entre conjuntos tradicionales

Unión ($R \cup S$)

Sea R y S relaciones definidas sobre $A \times B$, entonces:

$$R \cup S = \{(a, b) \mid (a, b) \in R, \text{ or } (a, b) \in S\}$$

$$R \cup S(a, b) = \max\{R(a, b), S(a, b)\}$$

Intersección ($R \cap S$)

$$R \cap S = \{(a, b) \mid (a, b) \in R, \text{ and } (a, b) \in S\}$$

$$R \cap S(a, b) = \min\{R(a, b), S(a, b)\}$$

Complemento ($\bar{R}$)

$$\bar{R} = \{(a, b) \mid (a, b) \notin R\}$$

$$\bar{R}(a, b) = 1 - R(a, b)$$

Composición ($R \circ S$)

Dados los conjuntos A , B y C , y las relaciones $R \subseteq A \times B$ y $S \subseteq B \times C$. Se define la composición $R \circ S$ como

$$R \circ S = \{(a, c) \mid (a, b) \in R, (b, c) \in S\}$$

es decir, existe un elemento b tal que $(a, b) \in R$

Anexo 3: Lógica tradicional

Lógica proposicional tradicional

- Se define como proposición toda sentencia que puede ser verdadera o falsa.
- Ejemplos:
 1. La rosa es roja.
 2. El tigre es un animal doméstico.
 3. El número primo más pequeño es el 5.
- Las proposiciones pueden ser expresadas por símbolos o expresiones simbólicas.
- En el cálculo de proposiciones, los símbolos pueden ser:
 1. Valores constantes lógicos 'Verdadero' (representado por V, T o 1), y 'Falso' (representado por F o 0).
 2. Proposiciones (representados con letras tales como a, b, p, q, etc.).
 3. Paréntesis.
 4. Operadores lógicos tales como
 - AND (conjunción, $\wedge$ o $\cdot$)
 - OR (disyunción, $\vee$ o $+$)
 - NOT (negación, $\neg$ o $'$)
 - IMPLICATION (condicional, $\rightarrow$)

Anexo 4: Modus Ponens y Modus Tollens Tradicionales

Modus Ponens

Es una regla de inferencia que permite obtener una conclusión a partir de una premisa condicional y la afirmación de su antecedente.

Forma general:

1. Si $p \rightarrow q$

2. p
3. Por lo tanto, q

Ejemplo:

1. Si llueve, entonces la calle se moja.
2. Llueve.
3. Por lo tanto, la calle se moja.

Modus Tollens

Es una regla de inferencia que permite obtener la negación del antecedente a partir de una premisa condicional y la negación de su consecuente.

Forma general:

1. Si $p \rightarrow q$
2. $\neg q$
3. Por lo tanto, $\neg p$

Ejemplo:

1. Si llueve, entonces la calle se moja.
2. La calle no está mojada.
3. Por lo tanto, no está lloviendo.