



## IPD-434 Seminario de Soft Computing



# Computación Evolutiva Avanzada

Dr. Nicolás Gálvez Ramírez

Ingeniería Civil Telemática

Departamento de Electrónica

Universidad Técnica Federico Santa María


Fuente: "Introduction to Evolutionary Computing", Gusz Eiben and James Smith.

## Computación Evolutiva

Metaheurísticas bio-inspiradas basadas en los principios de la **Teoría de la evolución y la selección natural** de Charles Darwin.


- Gran auge desde los 90s.
- Creadas en los 70s.
- Llamados **Algoritmos Evolutivos** (*EA, Evolutionary Algorithms*).
- Pioneras en algoritmos basados en la biología y la naturaleza.
- Amplía la búsqueda a varios candidatos simultáneos.
- Se perturban los candidatos con operadores evolutivos clásicos (y otros...)

## Algoritmos Evolutivos: Framework



## Tipos de Algoritmos Evolutivos

- Si bien existen variados tipos de algoritmos evolutivos o derivados. Se reconocen las siguiente 4 áreas principales:
  1. Programación Evolutiva
  2. Estrategias de Evolución
  3. **Algoritmos Genéticos**
  4. **Programación Genética**



## Algoritmos Genéticos (GA, *Genetic Algorithms*)

- Holland (1973), rectificado por De Jong (1975).
- Algoritmo básico y pionero de la Computación Evolutiva.
- Creación de generaciones nuevas basadas en cruzamiento y mutación.
- Población intermedia de padres que solo vive una (1) generación.

| Característica      | Aplicación                                    |
|---------------------|-----------------------------------------------|
| Representación      | Bit-Vector or Bit-String                      |
| Recombinación       | Cruzamiento a 1 punto, probabilístico         |
| Mutación            | Bit-flip (complemento de bit), probabilístico |
| Selección de Padres | Roulette-Wheel proporcional a Fitness         |
| Supervivencia       | Edad                                          |

## Programación Genética (*GP, Genetic Programming*)

- J. Koza (1990), derivación de GA cambiando la representación a árboles como individuos.
- Dual: Optimización y Máquina de Aprendizaje.
  - Maximiza retorno.
  - Maximiza ajuste a modelo.
- Moderno, pero tan exitoso que tiene su propia rama.
- Uso: lenguajes, código, expresiones, lógica, etc.

| Característica      | Aplicación                                 |
|---------------------|--------------------------------------------|
| Representación      | Árboles                                    |
| Recombinación       | Intercambio de sub-árboles                 |
| Mutación            | Cambio aleatorio en el árbol.              |
| Selección de Padres | Proporcional a Fitness (variadas técnicas) |
| Supervivencia       | Edad                                       |

## Repaso

### Función de Fitness

- Función de evaluación.
- Mide la calidad de los genotipos.
- Mide la adaptación (fit, ajuste) de los individuos al ambiente (evolución del sistema).
- Se hace decodificando los genotipos al espacio de los fenotipos.

### Población


- Multiconjunto que representa una selección de candidatos a solución.
  - Multiconjunto: Conjunto que puede tener valores repetidos.
- Individuos estáticos → **no** cambian.
- Poblaciones dinámicas → **evolucionan**.
- Su tamaño, *pop*, es generalmente constante (no varía en ejecución).
- Base para la aplicación de **operadores evolutivos**.

### Diversidad

- Medida de dispersión de diferentes soluciones presentes en la población.
- Busca controlar la exploración/explotación de la evolución.
- Métricas:
  - Cantidad de valores de funciones de fitness
  - Cantidad de diferentes fenotipos.
  - Cantidad de diferentes genotipos.
  - Medidas estadísticas (entropía)

## Criterios de Inicio

- Para iniciar un EA, se debe contar con una **población inicial**.
- Esta población puede ser generada con procesos heurístico.
- Se recomienda partir con una **diversidad** alta.
- Individuos → aleatorios → **población randomizada**.



## Criterios de Término

- Como gran parte de las metaheurísticas, los EAs no tienen un criterio fijo de detención.
  - Se programan para ir pasando por soluciones de calidad diversa
  - Pueden estar iterando eternamente.
- Criterios:
  - **Convergencia:** % de la población con mismo fitness (pérdida de diversidad)
  - Tiempo sin mejoras en la adaptación generacional.
  - Total de evaluaciones fitness hechas.
  - Número de Iteraciones.
  - Tiempo de ejecución.

# Pseudocódigo GA Standard

```
GA( $S$ )
  parameter(s):  $S$  – set of blocks
  output: superstring of set  $S$ 

  Initialization :
   $t \leftarrow 0$ 
  Initialize  $P_t$  to random individuals from  $S^*$ 
  EVALUATE-FITNESS-GA( $S, P_t$ )

  while termination condition not met
    do {
      Select individuals from  $P_t$  (fitness proportionate)
      Recombine individuals
      Mutate individuals
      EVALUATE-FITNESS-GA( $S, modified\ individuals$ )
       $P_{t+1} \leftarrow$  newly created individuals
       $t \leftarrow t + 1$ 
    }
  return (superstring derived from best individual in  $P_t$ )

procedure EVALUATE-FITNESS-GA( $S, P$ )
   $S$  – set of blocks
   $P$  – population of individuals
  for each individual  $i \in P$ 
    do {
      generate derived string  $s(i)$ 
       $m \leftarrow$  all blocks from  $S$  that are not covered by  $s(i)$ 
       $s'(i) \leftarrow$  concatenation of  $s(i)$  and  $m$ 
       $fitness(i) \leftarrow \frac{1}{\|s'(i)\|^2}$ 
    }
```

## Algoritmos basados en GA

La fama de los algoritmos genéticos y la programación genética radica en que son la base para diversos algoritmos evolutivos que usan sus principios siendo modificados en algunos de los siguientes elementos:

- Operadores de Selección.
- Operadores de Recombinación.
- Operadores de Mutación.
- Operadores de Supervivencia.

## Tipos de operadores de selección de evolución.

Recordemos:

Operadores que permite transmitir descendencia genética desde la generación actual.

### Selección Aleatoria


Selección aleatoria uniforme.

Sea  $P$  una población con  $|P|$  individuos, y  $N$  el conjunto de  $n$  padres a seleccionar. Podemos definir  $N$  como:

$$N = \{p \in P \mid rand_i(P) = n \wedge |N_i| < n\}$$

con:

- $rand()$ : Función uniforme aleatoria de selección de padres.
- $rand_i()$ : i-esimo llamado a la función  $rand()$ .
- $|N_i|$ : Cardinalidad del conjunto  $n$  en al llamar a  $rand_i()$ .



## Selección por Torneos

Selección de  $n$  padres por torneos basados en fitness (todos contra todos).

### Torneos Simples

Sea  $P$  una población  $|P|$  individuos, y  $T$  un torneo como un conjunto de  $t$  participantes. Podemos definir  $T$  como:

$$T = \{t \in P \mid rand_i(P) = t \wedge |T_i| < m\}$$


Luego, los padres seleccionados serán:

$$N = best(T, n, mode)$$

con:

- $mode$ : modo de torneo (llaves, round robin, etc)
- $best(T, n, mode)$ : función que selecciona los  $n$  mejores participantes de un torneo  $T$ .

**Los padres pueden ser escogidos en 1 torneo o en  $n$  torneos diferentes.**



## Torneos Dobles

Selección de  $n$  padres por  $n$  torneos diferentes sin repetir participantes.

Dado un conjunto  $\mathcal{T}$  de  $n$  torneos simples  $T_i$ .

$$N = \{best(T_i, 1, mode) \in P \mid T_i \cap T_j = \emptyset \wedge \forall j \neq i\}$$

## Selección Proporcional a Fitness


Criterios basados en el nivel de adaptación de los individuo previo a la selección.

## Selección por Ranking

Los individuos son clasificados por ranking para luego escoger  $n$  padres.

Los criterios de selección son:


- Elitista:  $n$  mejores.
- Pesimista:  $n$  peores.
- Aleatoria:  $n$  al azar.
- Combinación de las anteriores.



## Selección por Ruleta

Los individuos se les asigna una probabilidad de selección respecto a su valor de fitness con respecto al total de la población.

Así, queda una selección aleatorizada donde los mejores tienen mayor posibilidad de ser escogidos.




## Selección por Muestra Universal de Ruleta

Extensión de la selección por ruleta, cuya selección es  $n$  puntos fijos igual al número de padres a seleccionar.

La distancia entre los puntos fijos es igual a  $1/|P|$ .





## Tipos de Operadores de Mutación

Recordemos:


Operadores que permiten modificar elementos puntuales de individuos de la población.

### Mutación Aleatoria

Con cierta probabilidad  $p_m$ , se cambia los valores de uno o algunos de los genes de un individuo. Se aplican generalmente a la descendencia reciente generada por recombinación.

#### Mutación a Gen

Dada la selección aleatoria de un gen  $g$ , con probabilidad  $p_m$ , se cambia el valor de éste por uno de su dominio, seleccionado al azar.



#### Mutación Uniforme

Por cada gen  $g_i$ , con probabilidad  $p_{m_i}$ , se cambia su valor por uno de su dominio, seleccionado al azar.


|        |   |   |   |   |   |   |   |   |   |   |   |   |   |   |   |   |   |   |
|--------|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| parent | 1 | 1 | 1 | 1 | 1 | 1 | 1 | 1 | 1 | 1 | 1 | 1 | 1 | 1 | 1 | 1 | 1 |   |
| child  | 0 | 1 | 0 | 0 | 1 | 0 | 1 | 1 | 0 | 0 | 0 | 1 | 0 | 1 | 1 | 0 | 0 | 1 |

## Mutación por Permutación

Con probabilidad  $p_m$ , se generan modificaciones en el orden de los genes de un individuo.

Existen variados tipos:

- Mutación por inserción.
- Mutación por intercambio.
- Mutación por mezcla/revuelta.



## Mutación Gaussiana


Con probabilidad  $p_m$ , se genera una perturbación gaussiana sobre un gen  $g$  con valor  $x_g \in [a, b]$ . Vale decir, se obtiene sobre una Distribución Gaussiana (Normal)  $\mathcal{N}(x_g, \sigma)$  un valor que se le añade al gen.

$$x'_g = \min(\max(\mathcal{N}(x_g, \sigma), a), b)$$

$$x'_g = x_g + \sigma \mathcal{N}(0, 1)$$

Se aplica al igual que en la Mutación Aleatoria:

- Mutación a Gen
- Mutación Uniforme Gaussiana



## Tipos de Operadores de Recombinación

Recordemos

- Mezcla de la información genética de dos padres en uno o dos hijos.

### Recombinación por puntos

Recombinación itercalada entre padres basada en puntos de intercambios para generar una descendencia de máximo 2 individuos.


#### Recombinación a 1 punto.

A partir de un punto aleatoriamente generado, para ambos padres, se intercambian la información contenida entre ellos.



#### Recombinación a $k$ puntos.

A partir de  $k$  puntos aleatoriamente generado, para ambos padres, se intercambian la información contenida entre ellos, de forma intercalada.



## Recombinación Uniforme

Dada una cantidad de  $k$  de padres, se genera una cantidad  $l$  de hijos (generalmente 1), donde cada gen corresponde a un componente elegido aleatoriamente uniforme desde los padres.

### Recombinación por 2 padres




## Recombinación por Permutación

Recombinaciones que alteran el orden de los genes, y son aplicables generalmente a representaciones cuyo orden no implica invalidez de los individuos.

### Recombinación por Mapeo Parcial (PMX)

Se genera una división por  $k$  puntos de cruzamiento, en donde se intercambia una o varias secciones entre los padres para generar hasta 2 hijos incompletos.


El resto de los valores se mapea según la relación de orden entre las zonas intercambiadas. El resto mantiene su lugar.



## Recombinación por Orden (OX)

Se genera una división por  $k$  puntos de cruzamiento, en donde se intercambia una o varias secciones entre los padres para generar hasta 2 hijos incompletos.

A diferencia de PMX, el resto de los valores se mapea según la posición que tengan en padre del cual no proviene la sección recibida.



## Operadores de selección de supervivencia

Operadores que emulan la adaptabilidad al ambiente de la generación actual y/o su descendencia.

## Elitismo

- Capacidad de mantener en la generación al o a los mejores individuos de la generación anterior respecto a su adaptación (fitness).
- Variantes:
  - Mantener al mejor generador de hijos.
  - Mantener al mejor fenotipo.
  - Mantener al mejor genotipo.

## Ranking de Fitness

- Selección de  $n \leq size(pop)$  individuos ordenados según su valor de fitness.
- En el ranking participan padres e hijos.
- El tamaño de  $n$  depende de otros criterios de supervivencia.

## Edad de Individuos


- Eliminación de individuo según su edad.
- Simula la condición finita de permanencia de un individuo de una especie.
- Se define un parámetro de **máxima cantidad de generaciones** para los individuos.

## Ejemplo: Ranking de Supervivencia

| Rank | $p_{survival}$ | Rank | $p_{survival}$ | Rank | $p_{survival}$ | Rank | $p_{survival}$ |
|------|----------------|------|----------------|------|----------------|------|----------------|
| 1    | 0.100          | 6    | 0.075          | 11   | 0.045          | 16   | 0.020          |
| 2    | 0.095          | 7    | 0.070          | 12   | 0.040          | 17   | 0.015          |
| 3    | 0.090          | 8    | 0.065          | 13   | 0.035          | 18   | 0.010          |
| 4    | 0.085          | 9    | 0.060          | 14   | 0.030          | 19   | 0.005          |
| 5    | 0.080          | 10   | 0.055          | 15   | 0.025          | 20   | 0.000          |

## Ejemplo Activo: Problema del Vendedor Viajero

- Resuelva alguna instancia del TSP utilizando un Algoritmo Genético o basado en Algoritmos Genéticos. Compare sus resultados con sus compañeros.



## Derivaciones... Algoritmos Bío Inspirados


## Ant Colony Optimization

Algoritmo bío-inspirado en la auto-organización de las hormigas *Linepithema humile* en el proceso de búsqueda de comida.

- Las hormigas son agentes que buscan una solución.
- Cooperan entre sí para ir detectando mejores soluciones → convergencia.
- Posee manejo de memoria temporal → feromona.
- Poseen retroalimentación positiva y negativa.

## Ideas Básicas

- Feromona → memoria temporal → como se encontró una solución
- Feedback positivo → reforzar buenas formas → feromona++
- Feedback negativo → discipación temporal memoria → feromona--
- Equilibrio Feedback → explotar y explorar.
- Cooperativo → lo que hace una hormiga, afecta a otras.



## Ants System

Dado un grafo  $G = (V, A)$  con un conjunto  $V$  de nodos o vértices, y un conjunto  $A$  de enlaces o aristas.

- $b_i(t)$ : el número de hormigas en el nodo  $i$ , con  $i = \{1, 2, \dots, |N|\}$ .
- $m = \sum_i^{|N|} b_i(t) \rightarrow$  el número total de hormigas (agentes).

## Feromona: Actualización

La intensidad de la feromona  $\tau_{ij}(t + z)$  en la arista  $(i, j)$  en el instante  $(t + z)$  está dada por:

$$\tau_{ij} = (1 - \rho)\tau_{ij}(t) + \Delta\tau_{ij}(t + z)$$

donde  $\rho$  es el coeficiente de evaporación de la feromona y  $\Delta\tau_{ij}(t + z)$  es la cantidad de feromona dejada en el arco  $(i, j)$  en el instante  $(t + z)$ .

*Nota: no importa si el grafo es simétrico o que esté completamente conectado.*

## Feromona: Incremento

La cantidad de feromona dejada en un arco en un determinado instante está dado por:

$$\Delta\tau_{ij}(t + z) = \begin{cases} \frac{Q}{L_k} & \text{si la } k\text{-ésima hormiga usa el arco } (i, j) \\ 0 & \text{e.o.c} \end{cases}$$

donde  $Q$  es una constante (parámetro) y  $L_k$  es el valor de la solución encontrada por la  $k$ -ésima hormiga.

- Nota: La intensidad de feromona inicial es casi cero:  $\tau_{ij}(0) \rightarrow 0$ .

## Regla de Transición: ¿Cómo avanzan las hormigas?

La probabilidad de que un agente, avance de un nodo  $i$  al nodo  $j$  está dada por:

$$P_{ij}^k(t) = \begin{cases} \frac{[\tau_{ij}(t)]^\alpha [\eta_{ij}]^\beta}{\sum_{h \in \text{permitido}_k(t)} [\tau_{ih}(t)]^\alpha [\eta_{ih}]^\beta} & \text{si nodo } j \in \text{permitido}_k(t) \\ 0 & \text{e.o.c} \end{cases}$$

Donde:

- $\eta_{ij}$  es una heurística seleccionada respecto al problema a resolver; y
- $\alpha$  y  $\beta$  son parámetros que permiten decidir como se reparte el peso de la probabilidad entre la feromona y la heurística seleccionada.

## AS Pseudocódigo



```

Procedure Ant System
Inicializar
Para t=1 hasta el número de ciclos haga
  Inicio
    Para k = 1 hasta m haga
      Inicio
        repetir
          seleccionar la siguiente ciudad a visitar con probabilidad  $P_{ij}^k$ 
        hasta hormiga k complete su tour
        calcular largo  $L_k$  del tour d la hormiga k
      fin para
    Salvar la mejor solución encontrada hasta el momento
    Modifique los niveles  $\tau_{ij}$  de feromona
  Fin

```

Figure 1: Algoritmo AS

## AS Elitista

Variación de la función de actualización de la feromona, considerando a la hormiga que encuentra la solución como un super depositador de feromona, vale decir, amplificar su efecto.

$$\tau_{ij} = (1 - \rho)\tau_{ij}(t) + \Delta\tau_{ij}(t + z) + e\Delta\tau_{ij}^e(t)$$

donde:

$$\Delta\tau_{ij}^e(t) = \begin{cases} \frac{Q}{L^+} & \text{si la } (i, j) \in T^+ \\ 0 & \text{e.o.c} \end{cases}$$

con  $L^+$  es el valor de la mejor solución, y  $T^+$  es la configuración de la mejor solución.

## AS en TSP

```

Procedure AS-TSP
Inicializar
Para cada arco  $(i, j)$  haga
   $\tau_{ij}(0) = \tau_0$ 
fin para
Para k=1 hasta m haga
  Ubique la hormiga k en una ciudad elegida aleatoriamente
fin para
Sea  $T^+$  et tour más corto encontrado desde el inicio, y  $L^+$  su largo
Para t=1 hasta el número de ciclos haga
  Inicio
    Para k = 1 hasta m haga
      Inicio
        repetir
          seleccionar la siguiente ciudad a visitar con probabilidad  $P_{ij}^k$ 
        hasta hormiga k complete su tour
        calcular largo  $L_k$  del tour de la hormiga k
      fin para
    Salvar la mejor solución  $T^+$ ,  $L^+$ , encontrada hasta el momento
    Para cada arco  $(i, j)$  haga
      Modifique los niveles  $\tau_{ij}$  de feromona aplicando la siguiente regla:
      
$$\tau_{ij}(t) = (1 - \rho)\tau_{ij}(t) + \Delta\tau_{ij}(t) + e * \Delta\tau_{ij}^e(t) \quad (9)$$

    fin para
  Fin

```

Figure 2: Algoritmo AS-TSP

Ant Colony System

Particle Swarm Optimization